Validación VIES de empresas de HubSpot

Documentación del proyecto – Oscar – PHP 8.1, sin dependencias externas

1. Qué hace el script y cómo lo he planteado

Es una herramienta de línea de comandos con dos comandos. **setup** crea por API el grupo de propiedades *Ejercicio Vexco – Oscar* y las tres propiedades de texto de una línea en Companies (`vies_[nombre]_estado / _fecha / _motivo`); es idempotente (un 409 «ya existe» se trata como éxito). **run** recorre las empresas, valida y guarda.

Flujo de **run**, empresa a empresa:

- **Lectura**: `GET /crm/v3/objects/companies` paginando con el cursor *after* hasta que no hay más. Solo pido `nif_cif_vat` y mis tres propiedades; las empresas sin `nif_cif_vat` se ignoran.
- **Normalización** (`VatParser`): quita espacios, puntos y guiones, pasa a mayúsculas, identifica el país por el prefijo y comprueba el formato nacional.
- **Consulta a VIES** (`POST /check-vat-number`), en serie, con una pequeña pausa entre llamadas (300 ms, configurable).
- **Escritura**: `PATCH` inmediato de esa empresa con solo mis tres propiedades. Si el proceso se corta, lo ya guardado se conserva.
- **Resumen** final por consola y en `logs/`: leídas, con NIF, ya al día, procesadas, válidas, inválidas, con error temporal y omitidas, más fallos al guardar.

Datos de partida intactos: el único dato que se lee de la empresa es `nif_cif_vat` y nunca se escribe; cada PATCH lista explícitamente las tres propiedades propias. No uso ninguna otra propiedad de nombre parecido (ni *country* como pista de país).

Idempotencia. Una empresa se reprocesa solo si: (a) no tiene estado, (b) su estado es `ERROR_TEMPORAL`, o (c) tiene estado final pero `nif_cif_vat` se modificó después de la fecha guardada. Para (c) pido a HubSpot el historial de la propiedad (`propertiesWithHistory`) y comparo el timestamp del último cambio con mi fecha, así no necesito una cuarta propiedad con una copia del NIF. Dentro de una misma ejecución, un número repetido en varias empresas se consulta una sola vez. `--force` ignora todo esto y `--dry-run` no escribe nada.

2. Scopes de la service key y por qué

Scope	Para qué lo uso
crm.objects.companies.read	Listar empresas y leer `nif_cif_vat`, mis propiedades y el historial.
crm.objects.companies.write	Guardar el resultado (PATCH de las empresas).
crm.schemas.companies.read	Comprobar que existen `nif_cif_vat` y mis propiedades antes de ejecutar.
crm.schemas.companies.write	Crear el grupo y las propiedades en **setup**. Solo hace falta una vez: tras crearlas, se puede quitar de la key.

No he añadido scopes de contactos, deals, tickets ni de escritura genérica: el principio es el mínimo privilegio, porque la key vive en un fichero `.env` (excluido del repositorio con `.gitignore`). Si la key no tuviera un scope, el script se detiene con un mensaje claro (HTTP 401/403 se tratan como errores fatales).

3. Datos mal formados y errores de VIES

Principio rector: **solo marco INVALIDO cuando hay evidencia** (VIES dice explícitamente que no es válido, o el formato es imposible para el país). Ante cualquier duda técnica el estado es `ERROR_TEMPORAL`, nunca INVALIDO.

Situación	Estado	Motivo / tratamiento
Campo vacío, solo espacios o solo signos	OMITIDO	«Campo vacío» / «Sin caracteres alfanuméricos». No se llama a VIES.
Caracteres no válidos (símbolos, texto libre)	OMITIDO	«Contiene caracteres no válidos».
Prefijo de país fuera de VIES (GB, CH, US…) o texto tipo «PENDIENTE»	OMITIDO	Prefijo no cubierto por VIES (país fuera de la UE o formato irreconocible).
Sin prefijo y no parece NIF/CIF/NIE español	OMITIDO	No se puede deducir el país.

Situación	Estado	Motivo / tratamiento
Sin prefijo y con forma de NIF/CIF/NIE	se valida	Se asume ES (el campo se llama NIF/CIF). Se envía a VIES como ES + número.
Prefijo UE válido pero formato imposible (ej. ESB1234)	INVALIDO	«Formato incorrecto para ES». Ahorra una llamada.
VIES: valid = true	VALIDO	Motivo vacío; fecha ISO 8601 UTC.
VIES: valid = false / INVALID_INPUT	INVALIDO	Motivo con la respuesta de VIES.
MS_UNAVAILABLE, TIMEOUT, SERVICE_UNAVAILABLE, SERVER_BUSY, *_MAX_CONCURRENT_REQ*	ERROR_TEMPORAL	Hasta 3 intentos con espera 2 s y 4 s; si persiste, se guarda el código en el motivo.
HTTP 429, 5xx o fallo de red contra VIES	ERROR_TEMPORAL	Backoff exponencial con jitter (respeta Retry-After). No se marca inválida.
Respuesta inesperada o ilegible	ERROR_TEMPORAL	Conservador: ante la duda, reintentable.

Trampa importante de VIES: muchos fallos llegan con **HTTP 200** y un cuerpo `{"actionSucceed": false, "errorWrappers": [{"error": "MS_UNAVAILABLE"}]}`. Si solo se mirase el campo *valid*, una caída del servicio de un Estado miembro se leería como «número inválido». Por eso se inspeccionan *errorWrappers* antes que *valid*.

País caído: si un Estado miembro devuelve MS_UNAVAILABLE o TIMEOUT tras los reintentos, el resto de empresas de ese país se marcan `ERROR_TEMPORAL` en esa ejecución sin volver a llamar, para no machacar un servicio caído. La siguiente ejecución las reintenta.

Rate limit de HubSpot: un 429 se espera con Retry-After y se reintenta; si es el límite *diario* (policyName DAILY) se aborta limpiamente, porque reintentar no sirve, y el resumen se imprime igualmente.

4. Dudas, decisiones y mejoras

Decisiones que he tomado (y que preguntaría si pudiera):

- **Sin prefijo de país:** asumo España si encaja con NIF/CIF/NIE. Un número de 9 dígitos sin prefijo podría ser de otro país, pero no uso la propiedad *country* porque el enunciado limita el origen del dato a `nif_cif_vat`.
- **Formato imposible = INVALIDO, no OMITIDO:** el país está identificado y el número no puede existir, así que es una respuesta, no una imposibilidad de validar. Reservo OMITIDO para cuando no hay país identificable o está fuera de VIES.
- **Fecha en todos los estados:** el enunciado la pide para VALIDO; la guardo siempre como «fecha del último intento» porque es lo que permite la idempotencia (comparar con el último cambio del NIF) y saber cuándo se reintentó un error.
- **Motivo se vacía en VALIDO** para no dejar un motivo antiguo de un intento anterior.
- **GB / Irlanda del Norte:** GB se omite (fuera de la UE); XI (Irlanda del Norte) sí se valida porque VIES lo admite.
- **Listado completo + filtro en cliente** en lugar de la Search API: evita el límite de 10.000 resultados y detecta valores solo con espacios; a cambio lee empresas sin NIF. Con cuentas grandes cambiaría a Search con filtro HAS_PROPERTY.
- **Ejecución en serie**: VIES es un servicio público sin SLA que limita la concurrencia, así que la velocidad no compensa el riesgo de errores *_MAX_CONCURRENT_REQ.

Con más tiempo mejoraría:

- Tests automatizados con un servidor falso de HubSpot y VIES (hoy solo hay pruebas del normalizador) y una verificación de extremo a extremo contra el servicio de pruebas de VIES (*check-vat-test-service*).
- Enviar el NIF propio como *requester* a VIES para obtener el *requestIdentifier* (justificante de consulta) y guardarlo.
- Validar dígito de control localmente (p. ej. NIF/CIF/NIE español) para detectar errores tipográficos sin llamar a VIES.
- Revalidación periódica de los VALIDO (un NIF puede darse de baja del ROI) con una opción tipo `--older-than=90d`.
- Concurrencia limitada por país, guardado por lotes (batch/update) y reanudación con un cursor persistido para cuentas con muchos miles de empresas.

- Alertas (correo/Slack) cuando queden ERROR_TEMPORAL tras N ejecuciones, y logs en formato JSON para poder analizarlos.

Resultado de la ejecución real (cuenta Demo): 3.658 empresas leídas, 83 con `nif_cif_vat`; 69 VALIDO, 6 INVALIDO, 6 OMITIDO y 2 ERROR_TEMPORAL (MS_UNAVAILABLE de Alemania), sin fallos al guardar. En la segunda ejecución, 81 empresas quedaron «ya al día» y solo se reintentaron las 2 con error.